

TP - Modelado Estadístico

Allami Florencia - Vanotti Franco

Ejercicio 1

Empezamos cargando los datos y observando algunas sus métricas básicas y la distribución de sus atributos:

```
## animal_type dog          sexo          sterilized age_years
## Cat:60177 0:60177 Hembra:67197 0:109412 Min. : 0.000
## Dog:77629 1:77629 Macho :70609 1: 28394 1st Qu.: 0.083
##                                          Median : 1.000
##                                          Mean : 1.886
##                                          3rd Qu.: 2.000
##                                          Max. :24.000
##
## breed_main los desenlace
## Domestic Shorthair Mix :28638 Min. : 0.00 Adopcion :72993
## Domestic Shorthair :21359 1st Qu.: 3.11 Devolucion :20342
## Pit Bull Mix : 7456 Median : 6.86 Muerte : 5116
## Labrador Retriever Mix : 7187 Mean : 20.68 Transferencia:39355
## Chihuahua Shorthair Mix: 6041 3rd Qu.: 23.06
## Labrador Retriever : 3913 Max. :364.90
## (Other) :63212
```

Observando estos resultados, vemos que tenemos una gran cantidad de muestras (137,806). Tenemos más muestras de perros que de gatos (56,33% son perros), pero no es una diferencia significativa. La distribución de sexos es más equitativa aún (51,24%). Por otro lado, la mayoría de los animales no estaban esterilizados al llegar al refugio (79,40%).

La edad de los animales cuando llegaron al refugio es por lo general pequeña, con mediana de 1 año, y un promedio ligeramente mayor. Aún así, tenemos unos pocos casos más extremos, como el animal que entró con 24 años. Las edades se registran con números enteros, pero el tiempo de estadía está registrado con coma. La mayoría de los animales se quedaron menos de 24 días en el refugio, y el animal que se quedó más tiempo estuvo un año.

Respecto al desenlace, la mayoría de los animales del refugio fueron adoptados (52.9%), el resto siendo transferido (28.5%), devuelto (14.7%), o liquidado (3.7%).

Estudiando los datos, vemos que tenemos 473 razas distintas, 73 de gato y 400 de perro. En promedio tenemos 291.34 muestras por raza, pero la mediana es 22. La gran diferencia entre la media y la mediana nos da la indicación de que hay pocas razas muy representadas. Vemos la cantidad de animales por raza, contando solo razas con más de 100 animales.

Table 1: Las 5 razas con mayor cantidad de animales

Raza Principal	Cantidad	Porcentaje del Total	Porcentaje del Corte
Domestic Shorthair Mix	28638	20.78%	21.96%
Domestic Shorthair	21359	15.5%	16.38%
Pit Bull Mix	7456	5.41%	5.72%

Raza Principal	Cantidad	Porcentaje del Total	Porcentaje del Corte
Labrador Retriever Mix	7187	5.22%	5.51%
Chihuahua Shorthair Mix	6041	4.38%	4.63%

Explorando los datos, observamos que solo 120 de 473 razas tienen más de 100 muestras, y que solo 12 de ellas son gatos. Además, de esas razas, El Domestic Shorthair Mix es la más numerosa, representando el 20,78% de las muestras totales del dataset, y el 21,96% de las muestras del dataset filtrado.

También notamos que, aunque sacamos más de la mitad de las razas, el dataset que nos queda sigue teniendo una gran cantidad de muestras (130,423).


Ejercicio 2

Ahora vamos a estimar la tasa de adopción de cada raza, y vamos a medir si el estimador bayesiano empírico es más efectivo que el estimador de máxima verosimilitud

Inciso (a):

Con el fin de disponer de una referencia para evaluar la calidad de los estimadores, se definió como “tasa verdadera” de adopción de cada raza la proporción de animales adoptados sobre el total de animales de esa raza, calculada a partir del conjunto de datos completo. Siguiendo lo indicado en la consigna, se incluyeron únicamente las razas con al menos 100 observaciones, a fin de garantizar estimaciones confiables.

Luego de aplicar el filtro de al menos 100 animales por raza, se obtuvo un conjunto de razas para las cuales la proporción de adopciones calculada puede considerarse una aproximación confiable de la probabilidad real de adopción. Estas proporciones se utilizarán en el resto del trabajo como valores de referencia (o “verdad”) para evaluar el desempeño de los distintos estimadores.




La Figura 1 presenta las diez razas con mayor tasa de adopción estimada utilizando el conjunto completo de datos. Se observa que las tasas más altas se encuentran entre aproximadamente 0.65 y 0.75, destacándose Blue Lacy Mix como la raza con la mayor proporción de adopciones. Además, las diferencias entre las primeras posiciones son pequeñas, lo que evidencia que varias de estas razas presentan probabilidades de adopción similares.

Inciso (b):

Para cada una de las razas seleccionadas en el inciso anterior se extrajo una muestra aleatoria de $m=15$ animales y se calculó la correspondiente tasa cruda de adopción. La Tabla 2 presenta las estimaciones obtenidas para cada raza.

Table 2: Primeras cinco razas de la muestra

Raza Principal	Adoptados en la muestra	Tasa cruda
Alaskan Husky	5	33.33%
Alaskan Husky Mix	4	26.67%
American Bulldog	7	46.67%
American Bulldog Mix	5	33.33%
American Pit Bull Terrier	7	46.67%



La Figura 2 compara la tasa cruda obtenida a partir de la muestra con la tasa verdadera calculada utilizando el conjunto completo de datos. La línea roja representa la recta identidad ($y=x$), correspondiente al caso ideal en el que ambas tasas coinciden exactamente.


Se observa una asociación positiva entre ambas tasas; sin embargo, varios puntos se encuentran alejados de la recta identidad. Esto evidencia la elevada variabilidad de la tasa cruda cuando se estima a partir de solo 15 observaciones por raza, dando lugar tanto a sobreestimaciones como a subestimaciones de la tasa verdadera. Este comportamiento es esperable debido al reducido tamaño muestral, que incrementa la incertidumbre de las estimaciones.

En el siguiente inciso se analizará si el estimador Empirical Bayes permite reducir esta variabilidad mediante la incorporación de información proveniente del conjunto de razas.

Inciso (c):

Como paso previo a la construcción del estimador Empirical Bayes, se ajustó una distribución Beta a las tasas de adopción observadas para las distintas razas mediante el método de máxima verosimilitud. Los parámetros de la distribución ajustada se utilizarán como distribución a priori en los incisos siguientes.

El ajuste arrojó las estimaciones $\alpha_0=3.15$ y $\beta_0=3.44$.



La Figura 3 compara las estimaciones obtenidas mediante el método Empirical Bayes (puntos negros) y las tasas crudas (puntos azules) con la tasa verdadera de adopción calculada utilizando el conjunto completo de datos. La línea roja representa la recta identidad ($y=x$), correspondiente al caso ideal en el que la estimación coincide exactamente con la tasa verdadera.

Se observa que ambos estimadores presentan una relación positiva con la tasa verdadera; sin embargo, las estimaciones obtenidas mediante Empirical Bayes se encuentran, en general, más próximas a la recta identidad que las tasas crudas. En cambio, estas últimas exhiben una dispersión considerablemente mayor, reflejando la elevada variabilidad asociada al reducido tamaño muestral. Asimismo, puede observarse que las estimaciones Empirical Bayes tienden a desplazarse hacia el promedio global de las tasas de adopción, suavizando las sobreestimaciones y subestimaciones extremas que presentan las tasas crudas.

Este comportamiento se explica por el efecto de contracción (shrinkage) característico del enfoque Empirical Bayes, que incorpora información proveniente del conjunto de razas y atenúa las fluctuaciones aleatorias presentes en las muestras pequeñas. Como consecuencia, las estimaciones resultan más estables y, visualmente, muestran una mejor aproximación a la tasa verdadera que las tasas crudas. En el siguiente inciso se cuantificará esta diferencia mediante el cálculo del error cuadrático medio (MSE) para ambos estimadores.

Inciso (d):

Para comparar objetivamente ambos estimadores, se calculó el Error Cuadrático Medio (MSE) utilizando como referencia la tasa verdadera definida en el inciso (a). Esta métrica cuantifica, en promedio, la diferencia entre las estimaciones y el valor considerado como verdadero para cada raza.

Table 3: Comparación del Error Cuadrático Medio (MSE)

Estimador	MSE
Tasa cruda	0.0150
Empirical Bayes	0.0089

La Tabla 3 muestra que el estimador Empirical Bayes obtuvo un MSE de 0.0089, frente a 0.0150 para la tasa cruda. Esto representa una reducción del 40.7 % en el error cuadrático medio, indicando que, en promedio, las estimaciones obtenidas mediante Empirical Bayes se encuentran considerablemente más próximas a la tasa verdadera.

Estos resultados son consistentes con las observaciones realizadas en el inciso anterior. Mientras que la tasa cruda se basa exclusivamente en los 15 animales muestreados para cada raza y, por lo tanto, presenta una mayor variabilidad, el estimador Empirical Bayes incorpora información proveniente del conjunto de razas mediante la distribución a priori, lo que produce estimaciones más estables y reduce el error de estimación.

En conclusión, para este conjunto de datos y bajo el escenario planteado en la consigna, el estimador Empirical Bayes supera a la tasa cruda en términos de precisión, al proporcionar estimaciones sistemáticamente más cercanas a la tasa verdadera cuando el tamaño muestral por raza es reducido.

Ejercicio 3

Inciso (a):

Ahora vamos a trabajar con el modelo multinomial. El modelo multinomial es como el modelo binomial pero en más dimensiones. El modelo binomial nos habla de la probabilidad de éxitos en una cantidad de intentos, y el multinomial va a agregar dimensión definiendo distintos tipos de éxitos. En el ejemplo del refugio, por ejemplo, podemos hablar de las probabilidades de que un animal sea adoptado, transferido, devuelto o liquidado.

Inciso (b)

Vamos a crear un modelo multinomial a partir de los datos. Vamos a poner la variable **Desenlace** como resultado de una combinación lineal de las variables **age_years**, **dog**, **sterilized** y **sexo**. Hay cuatro tipos de desenlaces, y vamos a usar **Adopción** como variable de referencia.

```
Call: multinom(formula = desenlace ~ age_years + dog + sterilized + sexo, data = data_refugio, trace = FALSE)
```

```
Coefficients: (Intercept) age_years dog1 sterilized1 sexoMacho Devolucion -3.4747739 0.16620766 1.7009305 1.2524363
0.273606391 Muerte -2.8917130 0.24281216 -0.7075794 -0.3782199 0.258220482 Transferencia -0.4905999 0.08090993 -0.4257549
-0.2241343 -0.002062547
```

```
Std. Errors: (Intercept) age_years dog1 sterilized1 sexoMacho Devolucion 0.02582119 0.003122218 0.02393564 0.02058795
0.01763917 Muerte 0.02725511 0.004620294 0.03022470 0.04236217 0.02956384 Transferencia 0.01115315 0.003120335 0.01283847
0.02029064 0.01257725
```

Residual Deviance: 275489.1 AIC: 275519.1 El hecho de que **Adopción** sea la variable de referencia significa que para cada fila, estamos analizando la probabilidad de que el resultado sea la categoría de esa fila contra la probabilidad de que el resultado sea **Adopción**, normalizado para que todas las probabilidades sumen 1.

El modelo nos ofrece las métricas **Residual Deviance** y la **AIC**, que son métricas que nos permiten comparar la efectividad de distintos modelos, en particular los anidados. Dos modelos son anidados si las variables predictivas de uno son un subconjunto estricto de las del otro. La desviación (Deviance) nos habla de la distancia entre nuestras predicciones y los datos reales. Idealmente queremos minimizar esta distancia, sin embargo, solo mirar el desvío puede llevar a un sobreajuste. Un modelo completo siempre va a tener un desvío menor o igual que uno anidado restringido, pero no todas las variables predictivas aportan información real, a veces solo mejoran el desvío porque permiten el sobreajuste. Por eso, para evitar el uso de variables predictivas innecesarias, se puede penalizar el uso de muchas variables. Eso es lo que hace el AIC (Akaike Information Criterion), que evalúa el desvío y le agrega una penalización por complejidad, es decir, por cantidad de variables usadas.

Inciso (c)

Ahora analicemos los coeficientes. Los coeficientes de la fila **Devolución** representan el efecto de las variables predictoras sobre el log-odds (o el logaritmo de la razón de probabilidades) de que ocurra una **Devolución** en comparación con la categoría de referencia, **Adopción**. El coeficiente de **dog** es positivo, lo que significa que es más probable que el animal sea devuelto si es un perro. El módulo del coeficiente nos da su peso en el resultado.

Como esto es poco intuitivo, podemos ver también el factor de riesgo relativo. Se obtienen elevando e a estos coeficientes.

##	(Intercept)	age_years	dog1	sterilized1	sexoMacho
## Devolucion	0.03096883	1.180818	5.4790434	3.4988568	1.3146972
## Muerte	0.05548109	1.274829	0.4928357	0.6850798	1.2946242
## Transferencia	0.61225898	1.084273	0.6532765	0.7992078	0.9979396

Se interpretan de la siguiente forma: el riesgo relativo de **age_years** para **Muerte** es 1.27, lo que significa que cada año que le sumes a un animal multiplica la probabilidad de que el animal termine muerto en vez de adoptado por 1.27. Por otro lado, si es un perro (**dog1**), su probabilidad se multiplica por 0.49 con respecto


a su probabilidad si fuera un gato. Eso significa que, según nuestro modelo, si tenemos un perro y un gato con la misma edad y sexo, el perro va a tener menos probabilidades de morir que el gato.

Ejercicio 4

Inciso (a):


Curva de Kaplan-Meier Para analizar el tiempo hasta la adopción, se estimó la curva de Kaplan-Meier considerando como evento de interés la adopción del animal. Los restantes desenlaces (transferencia, devolución y muerte) fueron tratados como observaciones censuradas, ya que en esos casos el evento de adopción no fue observado durante el período de seguimiento.

Estimador de Kaplan-Meier



La Figura 5 presenta la curva de Kaplan-Meier estimada, que representa la probabilidad de que un animal permanezca sin ser adoptado después de un determinado número de días desde su ingreso al refugio. Se observa una disminución pronunciada durante los primeros días, lo que indica que una proporción importante de las adopciones ocurre poco tiempo después del ingreso. Posteriormente, la curva desciende de manera más gradual, reflejando que, a medida que transcurre el tiempo, la probabilidad de permanecer sin ser adoptado disminuye a un ritmo menor.

Probabilidad de Adopción Estimada A partir de la curva de supervivencia estimada se calculó la probabilidad acumulada de adopción, definida como $1 - \hat{S}(t)$, para distintos horizontes temporales. Los resultados se presentan en la Figura 6.




La probabilidad estimada de adopción es de aproximadamente 55.8 % a los 30 días, 78.4 % a los 60 días, 89.1 % a los 90 días y 97.1 % a los 180 días. Estos resultados muestran que la mayor parte de las adopciones ocurre durante los primeros meses de permanencia en el refugio. A partir de ese momento, la probabilidad acumulada continúa aumentando, aunque a un ritmo cada vez menor.

Es importante destacar que la probabilidad estimada mediante Kaplan-Meier no coincide necesariamente con la proporción observada de animales adoptados. Esto se debe a que los individuos cuyo desenlace fue transferencia, devolución o muerte se consideran observaciones censuradas y contribuyen al conjunto en riesgo hasta el momento en que son censurados, en lugar de ser tratados como casos que nunca experimentan el evento de interés.

Inciso (b):

Con el objetivo de identificar qué variables se asocian con tiempos de adopción diferentes, se estimaron curvas de Kaplan-Meier para distintos grupos de animales y se compararon mediante el test de Log-Rank. En todos los casos se consideró como evento la adopción, mientras que las transferencias, devoluciones y muertes fueron tratadas como observaciones censuradas.

Comparar perros vs gatos




La Figura 7 presenta las curvas de Kaplan-Meier para perros y gatos. Se observa que la curva correspondiente a los perros desciende más rápidamente durante los primeros días de permanencia en el refugio, lo que indica que estos animales tienden a ser adoptados en menor tiempo que los gatos. A medida que transcurren los días, las curvas se aproximan y, para tiempos de permanencia más prolongados, la correspondiente a los gatos queda levemente por debajo de la de los perros.

El test de Log-Rank arroja un estadístico $\chi^2 = 915$ con un $p \leq 2 \times 10^{-16}$, por lo que se rechaza la hipótesis nula de igualdad entre ambas curvas de supervivencia. En consecuencia, existe evidencia estadísticamente significativa de que el tipo de animal se encuentra asociado con el tiempo hasta la adopción.

Si bien las diferencias observadas entre las curvas no son muy pronunciadas a simple vista, el gran tamaño de la muestra hace que resulten estadísticamente significativas.

Comparar machos vs hembras

Kaplan-Meier segun sexo




Las curvas correspondientes a machos y hembras prácticamente se superponen durante todo el período de seguimiento, lo que sugiere que el sexo tiene un efecto muy reducido sobre el tiempo hasta la adopción.

No obstante, el test de Log-Rank resulta significativo ($\chi^2 = 22.3$, $p = 2 \times 10^{-6}$), por lo que se rechaza la hipótesis de igualdad entre ambas curvas. Esta significancia probablemente se explica por el gran tamaño de la muestra, que permite detectar diferencias muy pequeñas. En consecuencia, aunque la diferencia es estadísticamente significativa, su magnitud parece ser reducida desde un punto de vista práctico.

Esterilizados

Kaplan-Meier segun esterilizacion




Las curvas de Kaplan-Meier muestran que los animales que ingresan sin esterilizar presentan tiempos hasta la adopción menores que aquellos que ya se encontraban esterilizados al ingresar al refugio. Esta diferencia se mantiene durante gran parte del período de seguimiento, lo que sugiere una asociación consistente entre el estado de esterilización y el tiempo de adopción.

El test de Log-Rank confirma esta diferencia ($\chi^2 = 351$, $p \leq 2 \times 10^{-16}$), por lo que se rechaza la hipótesis nula de igualdad entre ambas curvas. En consecuencia, existe evidencia estadísticamente significativa de que el estado de esterilización se encuentra asociado con el tiempo hasta la adopción.

Edad Para estudiar el efecto de la edad, los animales se agruparon en tres categorías: menores de un año, entre uno y cinco años y mayores de cinco años.

Kaplan–Meier segun edad



Las curvas de Kaplan-Meier muestran un patrón claramente diferenciado entre los tres grupos. Los animales menores de un año presentan el descenso más pronunciado de la curva de supervivencia, lo que indica que, en promedio, son adoptados en menor tiempo. Los que tienen entre uno y cinco años muestran un comportamiento intermedio, mientras que los animales mayores de cinco años mantienen la curva de supervivencia más elevada durante gran parte del período de seguimiento, siendo el grupo que permanece más tiempo en el refugio antes de ser adoptado.

El test de Log-Rank confirma que las diferencias entre las curvas son estadísticamente significativas ($\chi^2 = 2468$, $p \leq 2 \times 10^{-16}$), por lo que existe evidencia de una asociación entre la edad y el tiempo hasta la adopción.

Conclusión En conjunto, los resultados muestran que el tiempo hasta la adopción se encuentra asociado con varias características del animal. En particular, la edad, el tipo de animal y el estado de esterilización presentan diferencias claras entre sus curvas de supervivencia, mientras que las curvas correspondientes a machos y hembras prácticamente se superponen. Si bien el test de Log-Rank detecta diferencias estadísticamente significativas para el sexo, estas parecen ser de escasa relevancia práctica debido al gran tamaño de la muestra.