

TP - Modelado Estadístico

Ejercicio 1

Empezamos cargando los datos y observando algunas métricas básicas, y la distribución de sus distintos atributos:

```
## animal_type dog          sexo          sterilized age_years
## Cat:60177 0:60177 Hembra:67197 0:109412 Min. : 0.000
## Dog:77629 1:77629 Macho :70609 1: 28394 1st Qu.: 0.083
##                                         Median : 1.000
##                                         Mean : 1.886
##                                         3rd Qu.: 2.000
##                                         Max. : 24.000
##
## breed_main los desenlace
## Domestic Shorthair Mix :28638 Min. : 0.00 Adopcion :72993
## Domestic Shorthair :21359 1st Qu.: 3.11 Devolucion :20342
## Pit Bull Mix : 7456 Median : 6.86 Muerte : 5116
## Labrador Retriever Mix : 7187 Mean : 20.68 Transferencia:39355
## Chihuahua Shorthair Mix: 6041 3rd Qu.: 23.06
## Labrador Retriever : 3913 Max. : 364.90
## (Other) :63212

## Rows: 137,806
## Columns: 8
## $ animal_type <fct> Dog, Dog, Dog, Dog, Dog, Dog, Dog, Dog, Cat, Cat, Dog, Dog~
## $ dog <fct> 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1~
## $ sexo <fct> Macho, Macho, Macho, Hembra, Hembra, Macho, Macho, Hembra,~
## $ sterilized <fct> 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1~
## $ age_years <dbl> 6, 10, 16, 15, 15, 15, 15, 18, 16, 14, 16, 14, 17, 13, 19,~
## $ breed_main <fct> Spinone Italiano Mix, Dachshund, Shetland Sheepdog, Labrad~
## $ los <dbl> 1.11, 4.97, 0.12, 0.87, 0.18, 0.21, 6.26, 0.05, 3.90, 14.1~
## $ desenlace <fct> Devolucion, Transferencia, Devolucion, Devolucion, Devoluc~
```

Observando estos resultados, vemos que tenemos una gran cantidad de muestras (137,806). Tenemos más muestras de perros que de gatos (56,33% son perros), pero no es una diferencia significativa. La distribución de sexos es más equitativa aún (51,24%). Por otro lado, la mayoría de los animales no estaban esterilizados al llegar al refugio (79,40%).

La edad de los animales cuando llegaron al refugio es por lo general pequeña, con mediana de 1 año, y un promedio ligeramente mayor. Aún así, tenemos unos pocos casos más extremos, como el animal que entró con 24 años. Las edades se registran con números enteros, pero el tiempo de estadía está registrado con coma. La mayoría de los animales se quedaron menos de 24 días en el refugio, y el animal que se quedó más tiempo estuvo un año.

Respecto al desenlace, la mayoría de los animales del refugio fueron adoptados (52.9%), el resto siendo transferido (28.5%), devuelto (14.7%), o liquidado (3.7%).

Otras métricas interesantes:

```
## Cantidad de razas distintas: 473
```

```
## Promedio de cantidad de muestras por raza: 291.3446
## Mediana de cantidad de muestras por raza: 22
## Hay 73 razas de gato y 400 razas de perro en el dataset
```

Podemos ver que hay una gran diferencia entre la media y la mediana, lo que nos da la indicación de que hay pocas razas muy representadas. Vemos la cantidad de animales por raza, contando solo razas con más de 100 animales.

```
## # A tibble: 120 x 4
##   breed_main      Cantidad `Porcentaje del total` `Porcentaje del corte`
##   <fct>          <int> <chr>          <chr>
## 1 Domestic Shorthair Mix 28638 20.78%        21.96%
## 2 Domestic Shorthair    21359 15.5%         16.38%
## 3 Pit Bull Mix          7456 5.41%         5.72%
## 4 Labrador Retriever Mix 7187 5.22%         5.51%
## 5 Chihuahua Shorthair M~ 6041 4.38%         4.63%
## 6 Labrador Retriever    3913 2.84%          3%
## 7 Pit Bull              3413 2.48%         2.62%
## 8 German Shepherd Mix   3306 2.4%          2.53%
## 9 Domestic Medium Hair ~ 2914 2.11%         2.23%
## 10 Chihuahua Shorthair   2835 2.06%         2.17%
## # i 110 more rows
```

```
## Tipos de razas de gatos con más de 100 muestras: 12
## Tipos de razas de perros con más de 100 muestras: 108
## Total de muestras en el dataset cortado: 130423
```

Podemos ver que solo 120 de 473 razas tienen más de 100 muestras, y que solo 12 de ellas son gatos. Además, de esas razas, El Domestic Shorthair Mix es el 20,78% de las muestras totales del dataset.

También se puede ver que, aunque sacamos más de la mitad de las razas, el dataset que nos queda sigue teniendo más de 130 mil muestras.

Ejercicio 2

Ahora vamos a estimar la tasa de adopción de cada raza, y vamos a medir si el estimador bayesiano empírico es más efectivo que el estimador de máxima verosimilitud

Inciso (a):


~~Para evaluar posteriormente la calidad de los estimadores, se definió como “tasa verdadera” de adopción de cada raza la proporción de animales adoptados sobre el total de animales de esa raza utilizando todo el conjunto de datos. Con el objetivo de obtener estimaciones confiables, se consideraron únicamente aquellas razas con al menos 100 observaciones, tal como indica la consigna.~~

Para tener una referencia a la hora de evaluar la calidad de los estimadores, se definió como “tasa verdadera” de adopción de cada raza la proporción de animales adoptados sobre el total de animales de esa raza utilizando todo el conjunto de datos. Con el objetivo de obtener estimaciones confiables, se consideraron únicamente aquellas razas con al menos 100 observaciones, tal como indica la consigna.


```
## # A tibble: 6 x 4
##   breed_main      n adoptados tasa_real
##   <chr>          <int>    <int>    <dbl>
## 1 Domestic Shorthair Mix 28638    14370    0.502
## 2 Domestic Shorthair    21359    13137    0.615
## 3 Pit Bull Mix          7456     3274    0.439
```

## 4 Labrador Retriever Mix	7187	4137	0.576
## 5 Chihuahua Shorthair Mix	6041	2948	0.488
## 6 Labrador Retriever	3913	2175	0.556

Luego de aplicar el filtro de al menos 100 animales por raza, se obtuvo un conjunto de razas para las cuales la tasa de adopción puede considerarse una aproximación confiable de la probabilidad real de adopción. Estas tasas se utilizarán posteriormente como referencia (“verdad”) para evaluar el desempeño de los distintos estimadores.



En la Figura 1 se observa una marcada diferencia en la cantidad de animales registrados entre las distintas razas. Las razas Domestic Shorthair Mix y Domestic Shorthair concentran una cantidad considerablemente mayor de observaciones que el resto, mientras que las demás presentan tamaños de muestra bastante menores. Esta diferencia justifica la necesidad de utilizar únicamente razas con un número suficiente de observaciones al definir la tasa verdadera.



La Figura 2 presenta las diez razas con mayor tasa de adopción calculada sobre el conjunto completo de datos. Se observa que las tasas más altas se encuentran entre aproximadamente 0.65 y 0.75, siendo Blue Lacy Mix la raza con la mayor proporción de adopciones dentro del grupo analizado. Asimismo, las diferencias entre las primeras posiciones son relativamente pequeñas, lo que indica que varias razas presentan probabilidades de adopción similares.

Inciso (b):

Con el objetivo de simular un escenario con información limitada, se tomó una muestra aleatoria de $m=15$ animales para cada una de las razas consideradas en el inciso anterior. A partir de estas muestras se calculó la tasa cruda de adopción, definida como la proporción de animales adoptados dentro de cada muestra. Esta estimación representa la aproximación que se obtendría si solo se dispusiera de una cantidad reducida de observaciones por raza.

yo esta explicación la sacaría

Fijar una semilla

Elegir el tamaño de muestra


Quedarnos solamente con las razas del inciso (a)

Tomar 15 animales por raza

Calcular la tasa cruda

```
## # A tibble: 6 x 3
##   breed_main      adoptados_muestra tasa_cruda
##   <chr>          <int>      <dbl>
## 1 Alaskan Husky         5      0.333
```

## 2 Alaskan Husky Mix	4	0.267
## 3 American Bulldog	7	0.467
## 4 American Bulldog Mix	5	0.333
## 5 American Pit Bull Terrier	7	0.467
## 6 American Pit Bull Terrier Mix	9	0.6



La Figura 3 compara la tasa cruda obtenida a partir de la muestra con la tasa verdadera calculada utilizando la totalidad de los datos. La línea roja representa la recta identidad ($y=x$), correspondiente al caso ideal en el que ambas tasas coinciden exactamente.

Se observa que, aunque existe una tendencia positiva entre ambas variables, numerosos puntos se encuentran alejados de la recta identidad. Esto indica que la tasa cruda presenta una variabilidad considerable cuando se estima a partir de únicamente 15 observaciones por raza. En algunos casos la tasa de adopción resulta sobreestimada, mientras que en otros se subestima respecto de la tasa verdadera.


Este comportamiento era esperable, ya que el tamaño muestral reducido incrementa la variabilidad de las estimaciones. En el siguiente inciso se evaluará si el estimador Empirical Bayes permite reducir este error incorporando información proveniente del conjunto completo de razas.

Inciso (c):

Con el objetivo de incorporar información global al proceso de estimación, se ajustó una distribución Beta a las tasas muestrales obtenidas en el inciso anterior mediante máxima verosimilitud.

Ajustar la distribución Beta

Los parámetros estimados fueron $\alpha_0=3.15$ y $\beta_0=3.44$, los cuales se utilizaron como distribución prior para construir el estimador Empirical Bayes.




La Figura 4 compara las estimaciones obtenidas mediante el método Empirical Bayes con la tasa verdadera de adopción calculada utilizando el conjunto completo de datos. La línea roja representa la recta identidad ($y=x$), correspondiente al caso ideal en el que la estimación coincide exactamente con la tasa verdadera.

Se observa una relación positiva entre ambas variables, ya que las estimaciones Empirical Bayes tienden a seguir la tendencia de las tasas verdaderas. La mayoría de las observaciones se concentra alrededor de la recta identidad, lo que indica que el estimador logra aproximar adecuadamente la tasa de adopción de cada raza aun cuando se dispone únicamente de una muestra reducida de animales.

Aunque aún se observan diferencias entre las estimaciones y la tasa verdadera, el efecto de contracción (shrinkage) propio del enfoque Empirical Bayes reduce la influencia de las fluctuaciones aleatorias presentes en las muestras pequeñas. En el siguiente inciso se cuantificará este comportamiento mediante el cálculo del error cuadrático medio (MSE), comparando el desempeño del estimador Empirical Bayes con el de la tasa cruda.

Inciso (d):

Para comparar objetivamente ambos estimadores se calcula el Error Cuadrático Medio (MSE), utilizando como referencia la tasa verdadera definida en el inciso (a). Esta métrica permite cuantificar, en promedio, qué tan alejadas se encuentran las estimaciones respecto del valor considerado como verdadero para cada raza.



La Figura 5 muestra que el estimador Empirical Bayes obtuvo un MSE de 0.0089, frente a 0.0150 para la tasa cruda. Esto representa una reducción del 40.7% en el error cuadrático medio, indicando que, en promedio, las estimaciones obtenidas mediante Empirical Bayes se encuentran considerablemente más próximas a la tasa verdadera.

Estos resultados son consistentes con el comportamiento observado en los gráficos de los incisos anteriores. Mientras que la tasa cruda depende exclusivamente de los 15 animales seleccionados para cada raza y, por lo tanto, puede verse fuertemente afectada por la variabilidad muestral, el estimador Empirical Bayes incorpora además la información global contenida en la distribución prior. Como consecuencia, las estimaciones extremas son suavizadas hacia el promedio general, reduciendo la influencia del azar y produciendo estimaciones más estables.

En conclusión, para este conjunto de datos y bajo el escenario planteado por la consigna, el estimador Empirical Bayes resulta preferible a la tasa cruda, ya que proporciona estimaciones más cercanas a la tasa verdadera cuando se dispone de una cantidad reducida de observaciones por raza.

Ejercicio 3

Inciso (a):

Ahora vamos a trabajar con el modelo multinomial. El modelo multinomial es como el modelo binomial pero en más dimensiones. El modelo binomial nos habla de la probabilidad de éxitos en una cantidad de intentos, y el multinomial va a agregar dimensión definiendo distintos tipos de éxitos. En el ejemplo del refugio, por ejemplo, podemos hablar de las probabilidades de que un animal sea adoptado, transferido, devuelto o liquidado.

Inciso (b)

Vamos a crear un modelo multinomial a partir de los datos. Vamos a poner la variable **Desenlace** como resultado de una combinación lineal de las variables **age_years**, **dog**, **sterilized** y **sexo**. Hay cuatro tipos de desenlaces, y vamos a usar **Adopción** como variable de referencia.

```
## Call:
## multinom(formula = desenlace ~ age_years + dog + sterilized +
##          sexo, data = data_refugio, trace = FALSE)
##
## Coefficients:
##          (Intercept)  age_years      dog1 sterilized1  sexoMacho
## Devolucion      -3.4747739  0.16620766  1.7009305   1.2524363  0.273606391
## Muerte          -2.8917130  0.24281216 -0.7075794  -0.3782199  0.258220482
## Transferencia  -0.4905999  0.08090993 -0.4257549  -0.2241343 -0.002062547
##
## Std. Errors:
##          (Intercept)  age_years      dog1 sterilized1  sexoMacho
## Devolucion      0.02582119  0.003122218  0.02393564  0.02058795  0.01763917
## Muerte          0.02725511  0.004620294  0.03022470  0.04236217  0.02956384
## Transferencia  0.01115315  0.003120335  0.01283847  0.02029064  0.01257725
##
## Residual Deviance: 275489.1
## AIC: 275519.1
```

El hecho de que **Adopción** sea la variable de referencia significa que para cada fila, estamos analizando la probabilidad de que el resultado sea la categoría de esa fila contra la probabilidad de que el resultado sea **Adopción**, normalizado para que todas las probabilidades sumen 1.

El modelo nos ofrece las métricas **Residual Deviance** y la **AIC**, que son métricas que nos permiten comparar la efectividad de distintos modelos, en particular los anidados. Dos modelos son anidados si las variables predictivas de uno son un subconjunto estricto de las del otro. La desviación (**Deviance**) nos habla de la distancia entre nuestras predicciones y los datos reales. Idealmente queremos minimizar esta distancia, sin embargo, solo mirar el desvío puede llevar a un sobreajuste. Un modelo completo siempre va a tener un desvío menor o igual que uno anidado restringido, pero no todas las variables predictivas aportan información real, a veces solo mejoran el desvío porque permiten el sobreajuste. Por eso, para evitar el uso de variables predictivas innecesarias, se puede penalizar el uso de muchas variables. Eso es lo que hace el **AIC** (**Akaike Information Criterion**), que evalúa el desvío y le agrega una penalización por complejidad, es decir, por cantidad de variables usadas.

Inciso (c)

Ahora analicemos los coeficientes. Los coeficientes de la fila **Devolución** representan el efecto de las variables predictoras sobre el log-odds (o el logaritmo de la razón de probabilidades) de que ocurra una **Devolución** en comparación con la categoría de referencia, **Adopción**. El coeficiente de **dog** es positivo, lo que significa que es más probable que el animal sea devuelto si es un perro. El módulo del coeficiente nos da su peso en el resultado.

Como esto es poco intuitivo, podemos ver también el factor de riesgo relativo. Se obtienen elevando e a estos coeficientes.

```
##          (Intercept)  age_years      dog1 sterilized1  sexoMacho
## Devolucion      0.03096883  1.180818  5.4790434   3.4988568  1.3146972
## Muerte          0.05548109  1.274829  0.4928357   0.6850798  1.2946242
## Transferencia  0.61225898  1.084273  0.6532765   0.7992078  0.9979396
```


Se interpretan de la siguiente forma: el riesgo relativo de **age_years** para **Muerte** es 1.27, lo que significa que cada año que le sumes a un animal multiplica la probabilidad de que el animal termine muerto en vez de

adoptado por 1.27. Por otro lado, si es un perro (dog1), su probabilidad se multiplica por 0.49 con respecto a su probabilidad si fuera un gato. Eso significa que, según nuestro modelo, si tenemos un perro y un gato con la misma edad y sexo, el perro va a tener menos probabilidades de morir que el gato.

Ejercicio 4


Inciso (a):

Curva de Kaplan-Meier Para analizar el tiempo hasta la adopción, se estimó la curva de Kaplan-Meier considerando como evento de interés la adopción del animal. Los restantes desenlaces (transferencia, devolución y muerte) fueron tratados como observaciones censuradas, ya que representan animales cuyo tiempo de adopción no pudo observarse dentro del estudio.



La Figura X presenta la curva estimada de Kaplan-Meier, que representa la probabilidad de que un animal permanezca sin ser adoptado luego de un determinado número de días en el refugio. Se observa una disminución pronunciada durante los primeros días, indicando que una gran proporción de las adopciones ocurre poco tiempo después del ingreso. Posteriormente, la curva desciende de forma más gradual, lo que sugiere que los animales que permanecen durante un período prolongado tienen una probabilidad cada vez menor de ser adoptados en el corto plazo.

Probabilidad de Adopción Estimada A partir de la curva de supervivencia se calculó la probabilidad acumulada de adopción, definida como $1 - \hat{S}(t)$, para distintos horizontes temporales. Los resultados se presentan en la Figura Y.



La probabilidad estimada de adopción alcanza aproximadamente un 55.8% a los 30 días, un 78.4% a los 60 días, un 89.1% a los 90 días y un 97.1% a los 180 días. Estos resultados indican que la mayor parte de las adopciones ocurre durante los primeros meses de permanencia en el refugio, mientras que el incremento en la probabilidad de adopción es cada vez menor a medida que transcurre el tiempo.


Es importante destacar que la probabilidad estimada mediante Kaplan-Meier no coincide necesariamente con el porcentaje observado de animales adoptados, ya que los individuos cuyo desenlace fue transferencia, devolución o muerte son tratados como observaciones censuradas y continúan aportando información hasta el momento en que abandonan el estudio.

Inciso (b):

Con el objetivo de identificar qué variables se asocian con tiempos de adopción diferentes, se estimaron curvas de Kaplan-Meier para distintos grupos de animales y se compararon mediante el test de Log-Rank. En todos los casos se consideró como evento la adopción, mientras que las transferencias, devoluciones y muertes fueron tratadas como observaciones censuradas.

Comparar perros vs gatos

Kaplan–Meier según tipo de animal




La Figura X muestra las curvas de Kaplan-Meier para perros y gatos. Se observa que la curva correspondiente a los perros desciende más rápidamente durante los primeros días de permanencia en el refugio, indicando una mayor velocidad de adopción. Sin embargo, para tiempos de permanencia más largos las curvas se aproximan y finalmente la correspondiente a los gatos queda levemente por debajo.

El test de Log-Rank arroja un estadístico $\chi^2 = 915$ con un $p \leq 2 \times 10^{-16}$, por lo que se rechaza la hipótesis de igualdad entre ambas curvas. En consecuencia, existe evidencia estadísticamente significativa de que el tipo de animal está asociado con el tiempo hasta la adopción.

Comparar machos vs hembras

Kaplan–Meier según sexo




Las curvas correspondientes a machos y hembras prácticamente se superponen durante todo el período de seguimiento, lo que sugiere que el sexo tiene un efecto muy pequeño sobre el tiempo de adopción.

No obstante, el test de Log-Rank resulta significativo ($\chi^2 = 22.3$, $p = 2 \times 10^{-6}$). Esta significancia probablemente se explica por el gran tamaño de la muestra, que permite detectar diferencias muy pequeñas. Desde un punto de vista práctico, el efecto del sexo sobre el tiempo de adopción parece poco relevante.

Esterilizados

Kaplan–Meier según esterilización




Las curvas de Kaplan-Meier muestran que los animales que ingresan sin esterilizar presentan tiempos de adopción menores que aquellos que ya se encontraban esterilizados al ingresar al refugio.

Estas diferencias son confirmadas por el test de Log-Rank ($\chi^2 = 351$, $p \leq 2 \times 10^{-16}$), por lo que existe evidencia estadísticamente significativa de una asociación entre el estado de esterilización y el tiempo de adopción.

Edad Para estudiar el efecto de la edad, los animales se agruparon en tres categorías: menores de un año, entre uno y cinco años y mayores de cinco años.

Kaplan–Meier según edad



Las curvas muestran un patrón muy marcado. Los animales de entre uno y cinco años presentan la caída más rápida de la curva de supervivencia, lo que indica que son adoptados en menor tiempo. Los menores de un año muestran una velocidad de adopción intermedia, mientras que los animales mayores de cinco años presentan la curva más alta durante casi todo el seguimiento, siendo el grupo que permanece más tiempo en el refugio antes de ser adoptado.

El test de Log-Rank confirma estas diferencias ($\chi^2 = 2468$, $p \leq 2 \times 10^{-16}$), constituyendo la asociación más fuerte observada entre todas las variables analizadas.

Conclusión En conjunto, los resultados muestran que el tiempo hasta la adopción depende de varias características del animal. La edad resulta ser la variable con mayor asociación con el tiempo de adopción, seguida por el tipo de animal y el estado de esterilización. Por el contrario, aunque el sexo presenta diferencias estadísticamente significativas debido al gran tamaño de la muestra, las curvas prácticamente se superponen, por lo que su efecto práctico parece ser reducido.