

TP - Modelado Estadístico

Ejercicio 1

Empezamos cargando los datos y observando su distribución

```
## animal_type dog          sexo          sterilized age_years
## Cat:60177    0:60177    Hembra:67197    0:109412    Min.      : 0.000
## Dog:77629    1:77629    Macho :70609    1: 28394    1st Qu.: 0.083
##                                           Median : 1.000
##                                           Mean   : 1.886
##                                           3rd Qu.: 2.000
##                                           Max.   :24.000
##
##                breed_main          los          desenlace
## Domestic Shorthair Mix :28638    Min.      : 0.00    Adopcion      :72993
## Domestic Shorthair     :21359    1st Qu.: 3.11    Devolucion    :20342
## Pit Bull Mix           : 7456    Median : 6.86    Muerte        : 5116
## Labrador Retriever Mix : 7187    Mean   : 20.68    Transferencia:39355
## Chihuahua Shorthair Mix: 6041    3rd Qu.: 23.06
## Labrador Retriever     : 3913    Max.   :364.90
## (Other)                :63212
```

Observando estos resultados, vemos que tenemos una gran cantidad de datos. La distribución entre perros y gatos es bastante pareja, aunque hay un poco más de perros. La distribución de sexos es más equitativa aún. Por otro lado, la mayoría de los animales no estaban esterilizados al llegar al refugio. La edad de los animales cuando llegaron al refugio es por lo general pequeña, pero tenemos algunos casos más extremos, como el animal que entró con 24 años. Las edades se registran con números enteros, pero el tiempo de estadía está registrado con coma.

Respecto al desenlace, la mayoría de los animales del refugio fueron adoptados (52.9%), el resto siendo transferido (28.5%), devuelto (14.7%), o liquidado (3.7%).

Hay también una gran variedad de razas representadas, en total, 473 razas distintas. Solo 120 de estas razas tienen más de 100 muestras. En promedio hay 291 muestras por especie y la mediana es 22 muestras por especie. De estas especies, 400 son de perro y 73 de gato.

```
## cantidad
## 1      473

## # A tibble: 120 x 2
##   breed_main          cantidad
##   <fct>              <int>
## 1 Domestic Shorthair Mix    28638
## 2 Domestic Shorthair       21359
## 3 Pit Bull Mix              7456
## 4 Labrador Retriever Mix    7187
## 5 Chihuahua Shorthair Mix   6041
## 6 Labrador Retriever        3913
## 7 Pit Bull                  3413
## 8 German Shepherd Mix      3306
## 9 Domestic Medium Hair Mix  2914
```

```
## 10 Chihuahua Shorthair          2835
## # i 110 more rows

## # A tibble: 473 x 2
##   breed_main          cantidad
##   <fct>              <int>
## 1 Domestic Shorthair Mix      28638
## 2 Domestic Shorthair        21359
## 3 Pit Bull Mix              7456
## 4 Labrador Retriever Mix     7187
## 5 Chihuahua Shorthair Mix    6041
## 6 Labrador Retriever        3913
## 7 Pit Bull                  3413
## 8 German Shepherd Mix       3306
## 9 Domestic Medium Hair Mix   2914
## 10 Chihuahua Shorthair      2835
## # i 463 more rows

## # A tibble: 1 x 2
##   promedio mediana
##   <dbl>   <int>
## 1    291.     22

## # A tibble: 2 x 2
##   animal_type cantidad
##   <fct>         <int>
## 1 Cat             73
## 2 Dog            400
```

Ejercicio 2

Inciso (a):

Para evaluar posteriormente la calidad de los estimadores, se definió como “tasa verdadera” de adopción de cada raza la proporción de animales adoptados sobre el total de animales de esa raza utilizando todo el conjunto de datos. Con el objetivo de obtener estimaciones confiables, se consideraron únicamente aquellas razas con al menos 100 observaciones, tal como indica la consigna.

```
verdad <- refugio %>%
  group_by(breed_main) %>%
  summarise(
    n = n(),
    adoptados = sum(desenlace == "Adopcion", na.rm = TRUE),
    tasa_real = adoptados / n,
    .groups = "drop"
  ) %>%
  filter(n >= 100) %>%
  arrange(desc(n))


head(verdad)
```

```
## # A tibble: 6 x 4
##   breed_main          n adoptados tasa_real
##   <chr>              <int>    <int>    <dbl>
## 1 Domestic Shorthair Mix 28638    14370    0.502
## 2 Domestic Shorthair    21359    13137    0.615
## 3 Pit Bull Mix          7456     3274    0.439
```

## 4 Labrador Retriever Mix	7187	4137	0.576
## 5 Chihuahua Shorthair Mix	6041	2948	0.488
## 6 Labrador Retriever	3913	2175	0.556

Luego de aplicar el filtro de al menos 100 animales por raza, se obtuvo un conjunto de razas para las cuales la tasa de adopción puede considerarse una aproximación confiable de la probabilidad real de adopción. Estas tasas se utilizarán posteriormente como referencia (“verdad”) para evaluar el desempeño de los distintos estimadores.


```
verdad %>%
  slice_max(n, n = 10) %>%
  ggplot(aes(
    x = reorder(breed_main, n),
    y = n,
    fill = breed_main
  )) +
  geom_col(show.legend = FALSE) + # también elimina la leyenda
  coord_flip() +
  labs(
    title = "Razas con mayor Cantidad de Animales",
    x = NULL,
    y = "Cantidad de Animales"
  ) +
  theme_minimal()
```



En la Figura 1 se observa una marcada diferencia en la cantidad de animales registrados entre las distintas razas. Las razas Domestic Shorthair Mix y Domestic Shorthair concentran una cantidad considerablemente mayor de observaciones que el resto, mientras que las demás presentan tamaños de muestra bastante

menores. Esta diferencia justifica la necesidad de utilizar únicamente razas con un número suficiente de observaciones al definir la tasa verdadera.

```
verdad %>%
  slice_max(tasa_real, n = 10) %>%
  ggplot(aes(x = reorder(breed_main, tasa_real), y = tasa_real, fill = breed_main)) +
  geom_col() +
  coord_flip() +
  labs(
    title = "Razas con mayor tasa real",
    x = NULL,
    y = "Tasa Real"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```



La Figura 2 presenta las diez razas con mayor tasa de adopción calculada sobre el conjunto completo de datos. Se observa que las tasas más altas se encuentran entre aproximadamente 0.65 y 0.75, siendo Blue Lacy Mix la raza con la mayor proporción de adopciones dentro del grupo analizado. Asimismo, las diferencias entre las primeras posiciones son relativamente pequeñas, lo que indica que varias razas presentan probabilidades de adopción similares.

Inciso (b):

Con el objetivo de simular un escenario con información limitada, se tomó una muestra aleatoria de $m=15$ animales para cada una de las razas consideradas en el inciso anterior. A partir de estas muestras se calculó la tasa cruda de adopción, definida como la proporción de animales adoptados dentro de cada muestra. Esta

estimación representa la aproximación que se obtendría si solo se dispusiera de una cantidad reducida de observaciones por raza.

Fijar una semilla

```
set.seed(123)
```

Elegir el tamaño de muestra

```
m <- 15
```

Quedarnos solamente con las razas del inciso (a)

```
muestra <- refugio %>%
```

```
  semi_join(verdad, by = "breed_main") # semi_join Simplemente elimina todas las razas que no están en .
```

Tomar 15 animales por raza

```
muestra <- muestra %>%  
  group_by(breed_main) %>%  
  slice_sample(n = m) %>%  
  ungroup()
```

Calcular la tasa cruda

```
tasa_cruda <- muestra %>%  
  group_by(breed_main) %>%  
  summarise(  
    adoptados_muestra = sum(desenlace == "Adopcion"),  
    tasa_cruda = adoptados_muestra / m,  
    .groups = "drop"  
  )
```


```
head(tasa_cruda)
```

```
## # A tibble: 6 x 3  
##   breed_main          adoptados_muestra tasa_cruda  
##   <chr>                <int>         <dbl>  
## 1 Alaskan Husky             5         0.333  
## 2 Alaskan Husky Mix         4         0.267  
## 3 American Bulldog         7         0.467  
## 4 American Bulldog Mix      5         0.333  
## 5 American Pit Bull Terrier 7         0.467  
## 6 American Pit Bull Terrier Mix 9         0.6
```

```
comparacion <- verdad %>%  
  left_join(tasa_cruda, by = "breed_main")
```

```
ggplot(comparacion,  
  aes(x = tasa_real,  
      y = tasa_cruda)) +  
  geom_point() +  
  geom_abline(  
    slope = 1,  
    intercept = 0,  
    color = "red"  
  ) +  
  labs(  
    title = "Tasa cruda vs. tasa verdadera",
```

```
x = "Tasa verdadera",
y = "Tasa cruda"
) +
theme_minimal()
```



La Figura 3 compara la tasa cruda obtenida a partir de la muestra con la tasa verdadera calculada utilizando la totalidad de los datos. La línea roja representa la recta identidad ($y=x$), correspondiente al caso ideal en el que ambas tasas coinciden exactamente.

Se observa que, aunque existe una tendencia positiva entre ambas variables, numerosos puntos se encuentran alejados de la recta identidad. Esto indica que la tasa cruda presenta una variabilidad considerable cuando se estima a partir de únicamente 15 observaciones por raza. En algunos casos la tasa de adopción resulta sobreestimada, mientras que en otros se subestima respecto de la tasa verdadera.

Este comportamiento era esperable, ya que el tamaño muestral reducido incrementa la variabilidad de las estimaciones. En el siguiente inciso se evaluará si el estimador Empirical Bayes permite reducir este error incorporando información proveniente del conjunto completo de razas.

Inciso (c):

Con el objetivo de incorporar información global al proceso de estimación, se ajustó una distribución Beta a las tasas muestrales obtenidas en el inciso anterior mediante máxima verosimilitud.

Ajustar la distribución Beta

```
fit_data <- tasa_cruda %>%
  filter(tasa_cruda > 0, tasa_cruda < 1) %>%
  pull(tasa_cruda)
```

```
ajuste <- fitdist(
  fit_data,
  "beta"
)
```

```
alpha0 <- ajuste$estimate["shape1"]
beta0 <- ajuste$estimate["shape2"]
```

```
alpha0
```

```
## shape1
## 3.15125
```


```
beta0
```

```
## shape2
## 3.441262
```

Los parámetros estimados fueron $\alpha_0=3.15$ y $\beta_0=3.44$, los cuales se utilizaron como distribución prior para construir el estimador Empirical Bayes.

```
comparacion <- comparacion %>%
  mutate(
    tasa_EB = (alpha0 + adoptados_muestra) /
              (alpha0 + beta0 + m)
  )
```

```
ggplot(comparacion,
  aes(x = tasa_real,
    y = tasa_EB)) +
  geom_point(alpha = 0.6, size = 2) +
  geom_abline(
    slope = 1,
    intercept = 0,
    color = "red"
  ) +
  labs(
    title = "Estimación Empirical Bayes vs. tasa verdadera",
    x = "Tasa verdadera",
    y = "Estimación Empirical Bayes"
  ) +
  theme_minimal()
```



La Figura 4 compara las estimaciones obtenidas mediante el método Empirical Bayes con la tasa verdadera de adopción calculada utilizando el conjunto completo de datos. La línea roja representa la recta identidad ($y=x$), correspondiente al caso ideal en el que la estimación coincide exactamente con la tasa verdadera.

Se observa una relación positiva entre ambas variables, ya que las estimaciones Empirical Bayes tienden a seguir la tendencia de las tasas verdaderas. La mayoría de las observaciones se concentra alrededor de la recta identidad, lo que indica que el estimador logra aproximar adecuadamente la tasa de adopción de cada raza aun cuando se dispone únicamente de una muestra reducida de animales.

Aunque aún se observan diferencias entre las estimaciones y la tasa verdadera, el efecto de contracción (shrinkage) propio del enfoque Empirical Bayes reduce la influencia de las fluctuaciones aleatorias presentes en las muestras pequeñas. En el siguiente inciso se cuantificará este comportamiento mediante el cálculo del error cuadrático medio (MSE), comparando el desempeño del estimador Empirical Bayes con el de la tasa cruda.

Inciso (d):

Para comparar objetivamente ambos estimadores se calcula el Error Cuadrático Medio (MSE), utilizando como referencia la tasa verdadera definida en el inciso (a). Esta métrica permite cuantificar, en promedio, qué tan alejadas se encuentran las estimaciones respecto del valor considerado como verdadero para cada raza.

Calcular los errores

```
comparacion <- comparacion %>%
  mutate(
    error_crudo = (tasa_cruda - tasa_real)^2,
    error_EB    = (tasa_EB - tasa_real)^2
  )
```



Calcular el MSE

```
mse_crudo <- mean(comparacion$error_crudo)

mse_EB <- mean(comparacion$error_EB)

mse_df <- data.frame(
  Estimador = c("Tasa cruda", "Empirical Bayes"),
  MSE = c(mse_crudo, mse_EB)
)

ggplot(mse_df, aes(x = Estimador, y = MSE, fill = Estimador)) +
  geom_col(width = 0.6, show.legend = FALSE) +
  geom_text(aes(label = sprintf("%.4f", MSE)),
            vjust = -0.5,
            size = 5) +
  scale_fill_manual(values = c("#5DA5DA", "#60BD68")) +
  scale_y_continuous(
    limits = c(0, max(mse_df$MSE) * 1.15)
  ) +
  labs(
    title = "Comparación del Error Cuadrático Medio",
    x = NULL,
    y = "Error Cuadrático Medio (MSE)"
  ) +
  theme_minimal(base_size = 12)
```



¿Por cuánto mejora?

```
mejora <- 100 * (mse_crudo - mse_EB) / mse_crudo
```

```
mejora
```

```
## [1] 40.70731
```

La Figura 5 muestra que el estimador Empirical Bayes obtuvo un MSE de 0.0089, frente a 0.0150 para la tasa cruda. Esto representa una reducción del 40.7% en el error cuadrático medio, indicando que, en promedio, las estimaciones obtenidas mediante Empirical Bayes se encuentran considerablemente más próximas a la tasa verdadera.

Estos resultados son consistentes con el comportamiento observado en los gráficos de los incisos anteriores. Mientras que la tasa cruda depende exclusivamente de los 15 animales seleccionados para cada raza y, por lo tanto, puede verse fuertemente afectada por la variabilidad muestral, el estimador Empirical Bayes incorpora además la información global contenida en la distribución prior. Como consecuencia, las estimaciones extremas son suavizadas hacia el promedio general, reduciendo la influencia del azar y produciendo estimaciones más estables.

En conclusión, para este conjunto de datos y bajo el escenario planteado por la consigna, el estimador Empirical Bayes resulta preferible a la tasa cruda, ya que proporciona estimaciones más cercanas a la tasa verdadera cuando se dispone de una cantidad reducida de observaciones por raza.

Ejercicio 3

Inciso (a):

El modelo multinomial es como el modelo binomial pero en más dimensiones. El modelo binomial nos habla de la probabilidad de éxitos en una cantidad de intentos, y el multinomial va a agregar dimensión definiendo distintos tipos de éxitos. En el ejemplo del refugio, por ejemplo, podemos hablar de las probabilidades de que un animal sea adoptado o transferido o devuelto o liquidado.

Inciso (b)

Vamos a crear un modelo multinomial a partir de los datos. Vamos a poner la variable `Desenlace` como resultado de una combinación lineal de las variables `age_years`, `dog`, `sterilized` y `sexo`. Hay cuatro tipos de desenlaces, y vamos a usar `Adopción` como variable de referencia.

```
# por default se ordenan alfabeticamente y toma la primera como referencia
model = multinom(desenlace ~ age_years + dog + sterilized + sexo,
                  data = data_refugio, trace = FALSE)
```

```
probs_quick <- predict(model, type = "probs")
summary(model)
```

```
## Call:
```

```
## multinom(formula = desenlace ~ age_years + dog + sterilized +
##          sexo, data = data_refugio, trace = FALSE)
```

```
##
```

```
## Coefficients:
```

```
##          (Intercept)  age_years      dog1 sterilized1  sexoMacho
## Devolucion    -3.4747739  0.16620766  1.7009305   1.2524363  0.273606391
## Muerte        -2.8917130  0.24281216 -0.7075794  -0.3782199  0.258220482
## Transferencia -0.4905999  0.08090993 -0.4257549  -0.2241343 -0.002062547
```

```
##
```

```
## Std. Errors:
```

```
##          (Intercept)  age_years      dog1 sterilized1  sexoMacho
```

```
## Devolucion      0.02582119 0.003122218 0.02393564 0.02058795 0.01763917
## Muerte          0.02725511 0.004620294 0.03022470 0.04236217 0.02956384
## Transferencia   0.01115315 0.003120335 0.01283847 0.02029064 0.01257725
##
## Residual Deviance: 275489.1
## AIC: 275519.1
```

El hecho de que **Adopción** sea la variable de referencia significa que para cada fila, estamos analizando la probabilidad de que el resultado sea la categoría de esa fila contra la probabilidad de que el resultado sea **Adopción**, normalizado para que todas las probabilidades sumen 1.

Viendo las métricas del modelo, tenemos la **Residual Deviance** y la **AIC**, que son métricas que nos permiten comparar modelos, en particular los anidados. Dos modelos son anidados si las variables predictivas de uno son un subconjunto estricto de las del otro. La Desviación nos habla de la distancia entre nuestras predicciones y los datos reales, y lo queremos minimizar. Sin embargo, solo mirar el desvío puede llevar a un sobreajuste, y un modelo completo siempre va a tener un desvío menor o igual que uno restringido. Para eso tenemos el **AIC** (Akaike Information Criterion), que evalúa el desvío y le agrega una penalización por complejidad.

Inciso (c)

Ahora analicemos los coeficientes. Los coeficientes de la fila **Devolución** representan el efecto de las variables predictoras sobre el log-odds (o el logaritmo de la razón de probabilidades) de que ocurra una **Devolución** en comparación con la categoría de referencia, **Adopción**. El coeficiente de **dog** es positivo, lo que significa que es más probable que sea devuelto si es un perro. El módulo del coeficiente nos da su peso en el resultado.

Como esto es poco intuitivo, podemos ver también el factor de riesgo relativo. Se obtienen elevando e a estos coeficientes.

```
##          (Intercept) age_years      dog1 sterilized1 sexoMacho
## Devolucion      0.03096883  1.180818 5.4790434    3.4988568 1.3146972
## Muerte          0.05548109  1.274829 0.4928357    0.6850798 1.2946242
## Transferencia   0.61225898  1.084273 0.6532765    0.7992078 0.9979396
```

Se interpretan de la siguiente forma: el riesgo relativo de **age_years** para Muerte es 1.27, lo que significa que cada año que le sumes a un animal multiplica la probabilidad de que el animal termine muerto en vez de adoptado por 1.27. Por otro lado, si es un perro, su probabilidad se multiplica por 0.49 con respecto a su probabilidad si fuera un gato. Eso significa que, según nuestro modelo, si tenemos un perro y un gato con la misma edad y sexo, el perro va a tener menos probabilidades de morir que el gato.